

실세계 데이터(RWD) 기반 약물부작용 AI 예측 모델 개발 가이드

입문 연구자를 위한 실무 안내서

NHIS · JMDC 데이터 활용을 중심으로

2026

목 차

Chapter 1 개요: RWD와 AI 예측 모델

- 1.1 실세계 데이터(RWD)의 정의와 특성
- 1.2 약물부작용 예측에서 AI의 역할
- 1.3 본 가이드의 목적과 구성

Chapter 2 데이터 소스의 이해: NHIS와 JMDC

- 2.1 국민건강보험공단(NHIS) 데이터
- 2.2 일본 JMDC 데이터
- 2.3 두 데이터 소스의 비교

Chapter 3 연구 설계

- 3.1 연구 질문 정의
- 3.2 대상 약물부작용 선정
- 3.3 연구 대상자 정의 및 코호트 설계

Chapter 4 데이터 전처리와 CDM 표준화

- 4.1 공통데이터모델(CDM) 개요
- 4.2 NHIS 데이터의 CDM 변환
- 4.3 JMDC 데이터의 CDM 변환
- 4.4 데이터 품질 점검

Chapter 5 변수 설계 및 특성 공학

- 5.1 변수 유형별 설계 전략
- 5.2 시간 의존적 변수 처리
- 5.3 결측치 및 불균형 데이터 처리

Chapter 6 AI 예측 모델 개발

- 6.1 모델 선택 가이드
- 6.2 모델 학습 및 하이퍼파라미터 튜닝
- 6.3 모델 해석가능성 확보

Chapter 7 모델 평가 및 검증

- 7.1 내적 검증 전략
- 7.2 외적 검증: 국제 데이터 교차 검증
- 7.3 성능 평가 지표

Chapter 8 임상 현장 적용을 위한 고려사항

8.1 CDSS 연동 방안

8.2 규제 및 인허가 경로

8.3 윤리적 고려사항

CHAPTER 1

개요: RWD와 AI 예측 모델

1.1 실세계 데이터(RWD)의 정의와 특성

실세계 데이터(Real-World Data, RWD)란 전통적인 무작위 대조 임상시험(RCT) 외부에서 일상적 의료 환경을 통해 수집되는 환자 건강 상태 및 의료 이용에 관한 데이터를 의미함. 건강보험 청구 데이터, 전자의무기록(EMR), 질병 등록 데이터, 환자 보고 결과 데이터 등이 이에 해당함.

RWD는 RCT 대비 대규모 인구집단을 포함하고, 실제 임상 환경에서의 약물 사용 패턴과 결과를 반영한다는 강점이 있음. 특히 약물부작용 연구에서는 RCT에서 확인하기 어려운 희귀 부작용이나 장기 사용에 따른 부작용을 탐지하는 데 유리함.

다만 RWD는 연구 목적으로 설계되지 않은 데이터이므로 선택 편향, 측정 오류, 교란 변수 등에 대한 체계적 고려가 필요함. 이러한 한계를 이해하고 적절히 보정하는 것이 RWD 기반 연구의 핵심 역량임.

RWD vs. RWE

실세계 데이터(RWD)는 원천 데이터 자체를 의미하고, 실세계 근거(Real-World Evidence, RWE)는 RWD를 적절한 연구 설계와 분석 방법론을 적용하여 도출한 임상적 근거를 의미함. RWD는 재료이고, RWE는 그 재료로 만든 결과물에 해당함.

1.2 약물부작용 예측에서 AI의 역할

전통적인 약물부작용 감시 체계는 부작용 발생 이후 보고·수집하는 사후적(reactive) 방식에 기반하고 있음. AI 예측 모델은 이를 사전적(proactive) 방식으로 전환할 수 있는 잠재력을 지님. 환자의 인구학적 특성, 진단 이력, 약물 처방 패턴, 검사 결과 등 다차원적 변수를 통합 분석하여 개별 환자의 약물부작용 발생 위험을 사전에 예측하는 것이 목표임.

특히 전통적 통계 모형으로는 포착하기 어려운 고차원 변수 간의 복잡한 상호작용을 학습할 수 있다는 점에서, 머신러닝 및 딥러닝 기법이 약물부작용 예측 영역에서 주목받고 있음.

1.3 본 가이드의 목적과 구성

본 가이드는 RWD를 활용한 약물부작용 AI 예측 모델 개발에 관심이 있는 입문 연구자를 대상으로, 연구 설계부터 모델 개발·검증, 임상 적용 고려사항까지의 전체 과정을 실무적으로 안내하는 것을 목적으로 함. 한국 국민건강보험공단(NHIS) 데이터와 일본 JMDC 데이터를 주요 데이터 소스로 다루며, 공통데이터모델(CDM) 기반 국제 데이터 표준화를 포함하여 다국가 연구 수행에 필요한 실무 지식을 제공함.

CHAPTER 2

데이터 소스의 이해: NHIS와 JMDC

■ 2.1 국민건강보험공단(NHIS) 데이터

국민건강보험공단(National Health Insurance Service, NHIS) 데이터는 한국의 전 국민 단일 건강보험 체계를 기반으로 축적된 국가 단위 보건의료빅데이터임. 약 5,200만 인구의 자격 정보, 의료 이용(진료·처방·시술), 건강검진 결과, 사망 정보 등을 포함하며, 장기간의 종적 추적이 가능함.

구분	주요 내용
자격 DB	성별, 연령, 소득분위, 거주지역, 장애등급 등 인구사회학적 정보
진료 DB	진단코드(KCD), 처방 약물(ATC/EDI), 시술·수술, 의료기관 유형 등
건강검진 DB	신체계측, 혈액검사(혈당·지질·간기능 등), 문진(흡연·음주·운동) 등
요양기관 DB	의료기관 종별, 소재지, 병상 수 등
사망 DB	사망일자, 사망 원인(사인코드) 등

표 1. NHIS 데이터의 주요 구성

NHIS 데이터의 강점은 전 국민을 포괄하는 대표성, 장기 종적 추적 가능성, 진단·처방·검진 정보의 연계 가능성에 있음. 다만 임상적으로 상세한 검사 결과(영상, 병리 등)나 처방 의도, 복약 순응도 등은 포함되지 않으며, 진단코드의 정확성이 청구 목적에 따라 달라질 수 있다는 한계가 있음.

■ 2.2 일본 JMDC 데이터

JMDC(Japan Medical Data Center) 데이터는 일본의 직장 건강보험조합 가입자를 대상으로 한 청구 데이터베이스임. 현직 근로자와 그 피부양자를 포함하며, 입원·외래 진료, 약국 조제, 건강검진 데이터를 포괄함. 약 1,600만 명 이상의 누적 데이터를 보유하고 있으며, 환자 단위의 종적 추적이 가능함.

JMDC 데이터는 약국 조제 데이터를 별도로 포함하고 있어 실제 약물 수령 내역을 확인할 수 있다는 강점이 있음. 다만 직장 건강보험 가입자 중심이므로 고령자(75세 이상)와 자영업자 등이 상대적으로 과소 대표될 수 있으며, 한국 NHIS와 달리 전 국민 대표성을 갖지는 않는다는 점에 유의해야 함.

■ 2.3 두 데이터 소스의 비교

구분	NHIS (한국)	JMDC (일본)
대상 인구	전 국민 (약 5,200만)	직장 건강보험 가입자 (누적 약 1,600만+)
대표성	전 국민 대표성	근로자 및 피부양자 중심
주요 데이터	자격, 진료, 건강검진, 사망	입원, 외래, 약국 조제, 건강검진
약물 정보	처방 기록 (EDI/ATC 코드)	처방 + 약국 조제 기록

진단 코드 체계	KCD (ICD-10 기반)	ICD-10
건강검진	국가건강검진 연계 가능	직장 건강검진 포함
고령자 포함	전 연령 포함	75세 이상 과소 대표
접근 방식	폐쇄망 (안전 작업 환경)	데이터 구매 계약

표 2. NHIS와 JMDC 데이터 소스 비교

다국가 데이터 활용의 의의

한국과 일본의 데이터를 함께 활용하면, 한 국가의 데이터에서 개발한 모델을 다른 국가의 데이터로 외적 검증할 수 있음. 이는 모델의 일반화 가능성(generalizability)을 평가하고, 인구집단 간 약물부작용 위험 요인의 차이를 비교 분석할 수 있는 기회를 제공함.

CHAPTER 3

연구 설계

■ 3.1 연구 질문 정의

명확한 연구 질문의 정의는 전체 연구의 방향을 결정하는 첫 단계임. 약물부작용 예측 연구에서는 일반적으로 다음과 같은 형태의 질문을 설정함.

- 대상 약물 X를 투여받은 환자에서 부작용 Y의 발생 위험을 예측할 수 있는가?
- 부작용 Y의 발생 고위험군을 사전에 식별할 수 있는 예측 인자는 무엇인가?
- 개발된 예측 모델이 다른 인구집단(예: 다른 국가)에서도 유효한가?

연구 질문은 PICO(S) 프레임워크를 활용하여 체계적으로 구조화하는 것이 바람직함. P(Patient/Population), I(Intervention/Exposure), C(Comparator), O(Outcome), S(Study design)를 명확히 정의하면 이후 코호트 설계와 변수 선정의 기준이 됨.

■ 3.2 대상 약물부작용 선정

예측 대상 약물부작용은 임상적 중요성, 발생 빈도, 데이터를 통한 포착 가능성을 종합적으로 고려하여 선정함. 청구 데이터에서는 진단코드와 처방 패턴의 변화를 통해 부작용 발생을 정의하게 되므로, 청구 데이터로 타당하게 정의할 수 있는(validated) 부작용을 선택하는 것이 중요함.

약물군	주요 부작용	청구 데이터 포착 가능성
항응고제 (와파린, NOAC)	출혈 (위장관, 두개내)	높음 - 진단코드 + 수혈/시술로 정의 가능
스타틴	근육병증/횡문근융해증	중간 - 진단코드 + CK 검사로 보완 필요
항혈소판제 (클로피도그렐 등)	출혈	높음 - 진단코드로 정의 가능
항부정맥제 (아미오다론 등)	갑상선 기능 이상, 폐독성	중간 - 진단코드 + 검사코드 조합
NSAIDs	위장관 출혈, 신손상	높음 - 진단코드로 정의 가능

표 3. 심혈관질환 관련 주요 약물부작용과 청구 데이터 포착 가능성

■ 3.3 연구 대상자 정의 및 코호트 설계

연구 대상자의 정의는 예측 모델의 적용 대상을 결정하는 핵심 단계임. 일반적으로 new-user design(신규 사용자 설계)을 기본으로 하여, 특정 약물을 처음 처방받은 시점을 index date로 설정하고, 이전 기간(look-back period)과 추적 기간(follow-up period)을 정의함.

- Index date: 대상 약물 최초 처방일
- Look-back period: index date 이전 환자 특성 파악 기간 (통상 1~3년)
- Follow-up period: 부작용 발생 관찰 기간 (부작용 유형에 따라 설정)
- Washout period: 이전 약물 사용 영향 배제를 위한 기간

주의: 시간 관련 편향

예측 모델 개발 시 미래 정보 유출(data leakage)에 특히 주의해야 함. index date 이후에 발생한 정보가 예측 변수에 포함되면 모델 성능이 과대 추정됨. 모든 예측 변수는 반드시 index date 이전 또는 index date 시점의 정보만 사용해야 함.

CHAPTER 4

데이터 전처리와 CDM 표준화

■ 4.1 공통데이터모델(CDM) 개요

공통데이터모델(Common Data Model, CDM)은 기관별·국가별로 상이한 구조의 의료 데이터를 표준화된 단일 형태로 변환하는 프레임워크임. 대표적으로 OHDSI(Observational Health Data Sciences and Informatics) 컨소시엄에서 개발한 OMOP CDM이 국제적으로 가장 널리 사용되고 있음.

CDM을 도입하면 서로 다른 데이터 소스(예: NHIS와 JMDC)에 동일한 분석 코드를 적용할 수 있어, 다국가 연구의 효율성과 재현성이 크게 향상됨. 또한 OHDSI 커뮤니티에서 제공하는 다양한 분석 도구 (ATLAS, HADES 등)를 활용할 수 있다는 실용적 이점이 있음.

OMOP CDM 주요 테이블	내용	활용 예시
PERSON	환자 기본 정보(성별, 생년 등)	대상자 정의, 인구학적 변수
CONDITION_OCCURRENCE	진단/상병 기록	동반질환, 결과변수(부작용) 정의
DRUG_EXPOSURE	약물 처방/투약 기록	대상 약물 노출, 병용 약물 변수
MEASUREMENT	검사/측정 결과	검사 수치 기반 변수 (eGFR 등)
OBSERVATION_PERIOD	관찰 기간 정보	데이터 가용 기간 확인
VISIT_OCCURRENCE	의료 이용 기록	입원/외래 방문 패턴 변수

표 4. OMOP CDM 주요 테이블과 약물부작용 예측 연구에서의 활용

■ 4.2 NHIS 데이터의 CDM 변환

NHIS 데이터를 OMOP CDM으로 변환하는 과정은 크게 구조적 매핑(structural mapping)과 용어 매핑(vocabulary mapping)으로 구성됨.

구조적 매핑에서는 NHIS의 테이블(자격, 진료, 검진 등)을 CDM 테이블로 대응시킴. 용어 매핑에서는 한국 고유의 코드 체계(KCD, EDI, 검진항목코드 등)를 OMOP 표준 용어(SNOMED-CT, RxNorm, LOINC 등)로 변환함. 특히 한국 고유 약물코드(EDI)에서 국제 표준 약물코드(RxNorm/ATC)로의 매핑은 약물부작용 연구에서 핵심적인 과정임.

■ 4.3 JMDC 데이터의 CDM 변환

JMDC 데이터의 CDM 변환도 유사한 과정을 따르되, 일본 고유의 코드 체계를 반영해야 함. 일본 진단코드(ICD-10 기반 표준병명마스터), 약물코드(YJ코드/HOT코드) 등을 OMOP 표준 용어로 매핑하는 작업이 필요함. JMDC의 약국 조제 데이터는 DRUG_EXPOSURE 테이블에 별도로 반영하여, 처방과 실제 조제 간의 차이를 구분할 수 있도록 설계함.

■ 4.4 데이터 품질 점검

CDM 변환 후에는 반드시 데이터 품질 점검을 수행해야 함. OHDSI에서 제공하는 Data Quality Dashboard(DQD)를 활용하면 체계적인 품질 평가가 가능함.

- 완전성(Completeness): 필수 필드의 결측 비율 확인
- 적합성(Conformance): 값의 형식과 범위가 CDM 규격에 부합하는지 확인
- 타당성(Plausibility): 데이터 값이 임상적으로 타당한 범위 내에 있는지 확인
- 일관성(Consistency): 테이블 간 데이터의 논리적 정합성 확인

ETL 스크립트의 공개와 공유

CDM 변환에 사용한 ETL(Extract-Transform-Load) 스크립트를 GitHub 등에 공개하면, 동일 데이터를 활용하는 연구자들의 중복 작업을 줄이고 변환 과정의 투명성을 확보할 수 있음. 오픈소스 공유는 연구 재현성 향상에 크게 기여함.

CHAPTER 5

변수 설계 및 특성 공학

■ 5.1 변수 유형별 설계 전략

약물부작용 예측 모델의 변수는 크게 인구학적 변수, 임상 변수, 약물 관련 변수, 의료 이용 변수로 구분할 수 있음. 각 유형별로 청구 데이터에서 추출 가능한 변수를 체계적으로 설계하는 것이 중요함.

변수 유형	주요 변수 예시	추출 소스 (CDM 테이블)
인구학적	연령, 성별, 소득분위(NHIS)	PERSON, OBSERVATION
동반질환	CCI 점수, 개별 동반질환 유무	CONDITION_OCCURRENCE
약물 관련	병용 약물 수, 특정 약물군 사용 여부	DRUG_EXPOSURE
검사 결과	eGFR, 간기능, 혈소판 수치 등	MEASUREMENT
의료 이용	입원 횟수, 외래 방문 빈도	VISIT_OCCURRENCE
과거 부작용력	이전 부작용 발생 이력 유무	CONDITION_OCCURRENCE

표 5. 약물부작용 예측 모델의 주요 변수 유형과 CDM 추출 소스

■ 5.2 시간 의존적 변수 처리

청구 데이터에서 추출하는 변수 중 상당수는 시간에 따라 변하는 시간 의존적(time-varying) 변수임. 예를 들어 병용 약물은 처방 시점에 따라 달라지고, 검사 수치도 시간에 따라 변동함. 이러한 변수를 적절히 처리하는 것이 모델 성능에 중요한 영향을 미침.

- 시점 고정 접근(Baseline approach): index date 기준 일정 기간 내 가장 최근 값 또는 평균값을 사용
- 시간 구간 분할 접근: look-back 기간을 여러 구간(예: 0~30일, 31~90일, 91~365일)으로 나누어 구간별 변수를 생성
- 순차 모델 접근: RNN, LSTM 등 순차 모델을 활용하여 시간 순서 정보를 직접 모델에 반영

■ 5.3 결측치 및 불균형 데이터 처리

청구 데이터에서는 검사 미시행으로 인한 결측치가 흔히 발생함. 이 경우 결측 자체가 '검사가 필요하지 않을 정도로 건강함'을 의미할 수 있으므로, 무작위 결측(MCAR)이 아닌 비무작위 결측(MNAR)의 가능성을 고려해야 함. 결측 여부 자체를 별도의 이진 변수로 포함시키는 방법도 유효한 전략임.

또한 약물부작용은 대부분 발생률이 낮아 결과 변수의 클래스 불균형(class imbalance)이 심한 경우가 많음. SMOTE, 언더샘플링, 비용 민감 학습(cost-sensitive learning), focal loss 등의 기법을 적용하여 불균형 문제를 완화할 수 있음.

주의: 과도한 오버샘플링

SMOTE 등 오버샘플링 기법은 반드시 학습 데이터에만 적용해야 하며, 검증/테스트 데이터에는 원본 분포를 그대로 유지해야 함. 교차 검증 시에도 각 fold 내에서 오버샘플링을 수행해야 데이터 누출을 방지할 수 있음.

CHAPTER 6

AI 예측 모델 개발

■ 6.1 모델 선택 가이드

약물부작용 예측에 활용 가능한 AI 모델은 다양하며, 데이터 특성과 연구 목적에 따라 적절한 모델을 선택해야 함. 입문 연구자에게는 해석 가능하고 구현이 상대적으로 용이한 모델부터 시작하여, 점진적으로 복잡한 모델로 확장하는 접근을 권장함.

모델	특성	적합한 상황
Logistic Regression	해석 용이, 기준 모델로 적합	변수 간 관계가 선형에 가까운 경우, 기준선 성능 확인
Random Forest	비선형 관계 포착, 변수 중요도 제공	변수 간 상호작용이 중요한 경우
Gradient Boosting (XGBoost, LightGBM)	높은 예측 성능, 결측치에 강건	정형 데이터에서 최적 성능 추구 시
Deep Neural Network	고차원 복잡 패턴 학습	대규모 데이터, 충분한 컴퓨팅 자원 보유 시
RNN / LSTM	순차적 시간 패턴 학습	시계열 처방/진단 데이터 활용 시

표 6. 약물부작용 예측에 활용 가능한 주요 AI 모델

입문자를 위한 권장 접근

처음 시작하는 연구자에게는 Logistic Regression을 기준 모델(baseline)로 먼저 구축하고, 이후 XGBoost 또는 LightGBM으로 성능 향상을 시도하는 단계적 접근을 권장함. 이 과정에서 데이터의 특성과 변수의 중요도에 대한 이해를 충분히 쌓은 후 딥러닝 모델로 확장하는 것이 효율적임.

■ 6.2 모델 학습 및 하이퍼파라미터 튜닝

모델 학습 과정에서는 학습 데이터와 검증 데이터를 적절히 분리하고, 하이퍼파라미터 튜닝을 통해 모델의 일반화 성능을 최적화해야 함.

- 데이터 분할: 학습(Training) / 검증(Validation) / 테스트(Test) 세트로 분할 (예: 7:1.5:1.5)
- 시간 기반 분할: 시간 순서에 따른 분할을 권장 (미래 데이터로 과거를 예측하는 오류 방지)
- 교차 검증: K-fold 또는 시간 기반 교차 검증(time-series split) 활용
- 하이퍼파라미터 탐색: Grid Search, Random Search, 또는 Bayesian Optimization 활용

■ 6.3 모델 해석가능성 확보

임상 현장 적용을 위해서는 모델의 예측 결과를 의료진이 이해하고 신뢰할 수 있어야 함. 블랙박스 모델이라 하더라도 사후 해석(post-hoc interpretation) 기법을 활용하여 예측에 기여하는 주요 요인을 설명할 수 있어야 함.

- SHAP (SHapley Additive exPlanations): 개별 예측에 대한 변수별 기여도를 정량적으로 제시
- LIME (Local Interpretable Model-agnostic Explanations): 개별 예측의 국소적 해석 제공
- Feature Importance: 전체 모델 수준에서의 변수 중요도 순위 제공
- Partial Dependence Plot (PDP): 특정 변수와 예측 결과 간의 관계를 시각화

CHAPTER 7

모델 평가 및 검증

■ 7.1 내적 검증 전략

내적 검증(internal validation)은 모델 개발에 사용한 데이터 내에서 모델의 성능과 안정성을 평가하는 과정임. 과적합(overfitting) 여부를 확인하고 모델의 신뢰성을 검증하는 데 필수적임.

- Hold-out 검증: 별도로 분리한 테스트 세트에서의 성능 평가
- K-fold 교차 검증: 데이터를 K개 fold로 나누어 반복 검증 (통상 5-fold 또는 10-fold)
- Bootstrap 검증: 복원 추출을 통한 반복 검증으로 성능의 신뢰구간 추정
- 시간 기반 검증: 특정 시점 이전 데이터로 학습, 이후 데이터로 검증 (temporal validation)

특히 약물부작용 예측에서는 시간 기반 검증(temporal validation)이 중요함. 의료 환경과 처방 패턴은 시간에 따라 변화하므로, 과거 데이터로 학습한 모델이 이후 시점의 환자에게도 유효한지를 확인하는 것이 임상 적용의 전제 조건임.

■ 7.2 외적 검증: 국제 데이터 교차 검증

외적 검증(external validation)은 모델 개발에 사용하지 않은 독립적 데이터에서 모델 성능을 평가하는 과정으로, 모델의 일반화 가능성(generalizability)을 검증하는 가장 강력한 방법임.

NHIS와 JMDC 두 데이터를 보유한 연구에서는 다음과 같은 교차 검증 전략을 활용할 수 있음.

- 전략 A: NHIS 데이터로 모델 개발 → JMDC 데이터로 외적 검증
- 전략 B: JMDC 데이터로 모델 개발 → NHIS 데이터로 외적 검증
- 전략 C: 두 데이터를 통합하여 모델 개발 → 각 데이터에서 하위 그룹별 성능 평가

국제 교차 검증에서 성능 저하가 관찰되는 경우, 이는 인구집단 특성의 차이, 의료 체계의 차이, 코딩 관행의 차이 등 다양한 요인에 기인할 수 있으므로, 원인 분석을 함께 수행하는 것이 바람직함.

■ 7.3 성능 평가 지표

평가 지표	의미	약물부작용 예측에서의 고려사항
AUROC	모델의 전반적 판별 능력	가장 기본적 지표. 불균형 데이터에서는 보완 필요
AUPRC	양성 클래스 예측의 정밀도-재현율 균형	클래스 불균형 시 AUROC보다 유용
Sensitivity (Recall)	실제 부작용 환자 중 정확히 예측한 비율	부작용 감지율. 임상적으로 매우 중요
Specificity	부작용 미발생 환자 중 정확히 예측한 비율	불필요한 경고 최소화와 관련
PPV (Precision)	양성 예측 중 실제 양성의 비율	경고 피로 최소화에 중요
Calibration	예측 확률과 실제 발생률의 일치도	임상 의사결정에 필수적. Calibration plot으로 평가

표 7. 약물부작용 예측 모델의 주요 성능 평가 지표

Calibration의 중요성

약물부작용 예측에서 calibration(보정)은 매우 중요함. 모델이 '30% 위험'이라고 예측했을 때, 실제로 해당 환자군에서 약 30%가 부작용을 경험해야 의료진이 이 수치를 의사결정에 활용할 수 있음. AUROC가 높더라도 calibration이 불량하면 임상 적용이 어려울 수 있음.

CHAPTER 8

임상 현장 적용을 위한 고려사항

■ 8.1 CDSS 연동 방안

개발된 예측 모델을 실제 임상 현장에서 활용하기 위해서는 임상 의사결정지원시스템(Clinical Decision Support System, CDSS)으로 구현하여 의료기관의 처방전달시스템(CPOE) 또는 전자의무기록(EMR)에 연동하는 것이 필요함.

CDSS 연동 시 핵심 고려사항은 다음과 같음.

- 실시간 예측: 처방 시점에 환자 데이터를 자동 수집하여 부작용 위험도를 즉시 산출할 수 있어야 함
- 직관적 인터페이스: 의료진의 업무 흐름을 방해하지 않으면서 핵심 정보를 간결하게 전달해야 함
- 경고 차등화: 위험도 수준에 따라 경고 강도를 차등 적용하여 경고 피로를 최소화해야 함
- 근거 제시: 예측 결과와 함께 주요 위험 요인을 의료진에게 제시하여 (SHAP 등 활용) 신뢰성을 확보해야 함
- 표준 연동: HL7 FHIR 및 CDS Hooks 표준을 활용하여 다양한 EMR 시스템에 범용적으로 연동 가능하도록 설계함

■ 8.2 규제 및 인허가 경로

AI 기반 예측 모델을 의료기기로서 임상에 적용하기 위해서는 관련 규제 요건을 충족해야 함. 한국 식품의약품안전처는 AI 기반 의료기기에 대한 허가·심사 가이드라인을 운영하고 있으며, 예측 모델의 용도와 위험 등급에 따라 인허가 절차가 달라짐.

연구 단계에서부터 향후 인허가 가능성을 고려하여, 모델 개발 과정의 문서화, 학습 데이터의 특성 기록, 성능 평가 프로토콜의 사전 설정, 모델 업데이트 계획 등을 체계적으로 관리하는 것이 바람직함.

■ 8.3 윤리적 고려사항

AI 예측 모델의 임상 적용에는 여러 윤리적 고려사항이 수반됨.

- 공정성(Fairness): 성별, 연령, 인종 등 특정 하위 그룹에서 모델 성능이 편향되지 않는지 검증
- 투명성(Transparency): 모델의 작동 원리와 한계를 의료진과 환자에게 적절히 설명
- 자율성(Autonomy): AI 예측은 의료진의 의사결정을 '보조'하는 것이며, 최종 판단은 의료진에게 있음을 명확히 함
- 개인정보보호: 모델 학습 및 적용 전 과정에서 환자 개인정보의 보호와 데이터 보안을 철저히 준수
- 지속적 모니터링: 임상 적용 후에도 모델 성능의 변화(performance drift)를 지속적으로 모니터링하고 필요 시 재학습

모델 성능 저하(Model Drift)에 대한 경고

의료 환경, 처방 가이드라인, 코딩 관행 등은 시간에 따라 변화함. 이로 인해 과거 데이터로 학습한 모델의 성능이 시간이 지남에 따라 저하될 수 있음(model drift). 임상 적용 시에는 주기적 성능 모니터링과 재학습 계획을 반드시 수립해야 함.

본 가이드는 RWD 기반 약물부작용 AI 예측 모델 개발의 전체 과정을 입문 연구자의 관점에서 개괄하였음. 실제 연구 수행 시에는 각 단계별로 보다 심층적인 방법론적 검토와 전문가 자문이 필요하며, OHDSI 커뮤니티, 관련 학회, 최신 문헌 등을 통해 지속적으로 지식을 업데이트해 나가기를 권장함.

© 2026 [저작자명/연구팀명]. 본 저작물은 크리에이티브 커먼즈 저작자표시-비영리-동일조건변경허락 4.0 국제 라이선스(CC BY-NC-SA 4.0)에 따라 이용할 수 있습니다. <https://creativecommons.org/licenses/by-nc-sa/4.0/deed.ko>